Mantendo Tutores Baseados em LLM no Modo Socrático: um Mapeamento Sistemático de Técnicas de Projeto

Abstract. *LLM-based tutors tend to hand out answers, which can undermine learning. This systematic mapping study identifies design techniques that keep LLM tutors in Socratic mode: inducing guiding behaviour (RQ1), controlling memory, reasoning and dialogue state (RQ2), and resisting pressure for answers (RQ3). From 149 records (IEEE Xplore, ACM DL, Scopus, arXiv), 67 primary studies were included. Prompt engineering is almost universal (65 studies). Training-based approaches appear in 10, all in the laboratory and half in preprints. Hint ladders (25) and student models (24) dominate state control; 21 studies move disclosure control outside the LLM. Only 31 studies address answer-seeking pressure and 8 evaluate it adversarially, just 1 in a real course.*

Resumo. *Tutores baseados em LLM tendem a entregar respostas, prejudicando a aprendizagem. Este mapeamento identifica técnicas que os mantêm no modo socrático: indução do comportamento orientador (QP1), controle de memória, raciocínio e estado do diálogo (QP2) e resistência à pressão por respostas (QP3). De 149 registros (IEEE Xplore, ACM DL, Scopus e arXiv), 67 estudos foram incluídos. Prompts são quase universais (65 estudos). Abordagens de treinamento aparecem em 10, todas em laboratório e metade em preprints. Escadas de dicas (25) e modelos do estudante (24) dominam o controle de estado; 21 estudos deslocam o controle da revelação para fora do LLM. Só 31 tratam a pressão por respostas e 8 a avaliam adversarialmente, 1 em curso real.*

1. Introdução

Modelos de linguagem de grande porte (*Large Language Models*, LLMs) passaram a ser usados como tutores conversacionais em escala. Otimizados para serem úteis, porém, esses modelos tendem a fornecer respostas completas, o que reduz o esforço cognitivo do estudante e cria o risco de *cognitive offloading*. Em um estudo do corpus, usuários frequentes de um assistente de perguntas e respostas formularam significativamente menos perguntas de ordem superior [Perez 2026]. Em outro, adolescentes que haviam escolhido receber apoio guiado concentraram a interação em pedidos instrumentais e de resposta [Abdelghani et al. 2026].

Uma resposta comum é projetar o tutor para agir de forma *socrática*: guiar por perguntas e *scaffolding*, retendo a resposta final. Manter esse comportamento, contudo, é um problema de projeto não trivial. O modelo precisa ser induzido a orientar em vez de responder, precisa regular quanto ajuda oferecer ao longo do diálogo e precisa resistir a estudantes que insistem, reformulam ou tentam *jailbreaks* para obter a resposta.

Este artigo apresenta um mapeamento sistemático, conduzido conforme [Petersen et al. 2008, Petersen et al. 2015], cujo objetivo, no formato GQM, é: *analisar* estudos primários *com o propósito de* caracterizar as técnicas de projeto que sustentam o comportamento socrático de agentes tutores baseados em LLM *do ponto de vista de* pesquisadores e desenvolvedores de tecnologia educacional *no contexto da* educação formal e informal. As contribuições são: (i) um esquema de classificação para as três questões

de pesquisa; (ii) o mapa de 67 estudos primários; e (iii) a identificação de lacunas e implicações para pesquisa e desenvolvimento.

2. Fundamentação e Trabalhos Relacionados

O método socrático conduz o aprendiz por perguntas que o levam a explicitar, examinar e revisar o próprio raciocínio, em vez de receber conclusões prontas. Em tutoria, ele se articula com a noção de Zona de Desenvolvimento Proximal (ZDP): a ajuda deve situar-se entre o que o estudante faz sozinho e o que faz com apoio, sendo retirada gradualmente (*fading*). A taxonomia de Bloom, por sua vez, orienta o nível cognitivo das perguntas. Em agentes baseados em LLM, esses princípios precisam ser traduzidos em mecanismos concretos: instruções, estado do diálogo, políticas de revelação e salvaguardas.

A busca recuperou 7 estudos secundários (excluídos por CE4). Uma revisão analisa como a adaptatividade é realizada em sistemas tutores que integram LLMs [El Yabouri and Hibbi 2026]; outra revisa arquiteturas conversacionais com repetição espaçada para aquisição de vocabulário [Ramadhan and Falih 2025]; e uma terceira relaciona teorias de pedagogia dialógica às capacidades dos LLMs e propõe estratégias de *prompt* para alinhá-los [Beale 2025]. Essas revisões tratam da adaptatividade em geral, de um domínio específico ou da fundamentação teórica. Nenhuma delas mapeia especificamente as técnicas que *impedem a revelação prematura da resposta* e que *resistem à pressão do estudante*, que é o foco deste mapeamento.

3. Método

O estudo segue as diretrizes de mapeamento sistemático e de revisão da literatura em engenharia de software [Petersen et al. 2008, Petersen et al. 2015, Kitchenham and Charters 2007]. As questões de pesquisa são: **QP1** (indução do comportamento socrático) – que estratégias (engenharia de *prompts*, personas, *few-shot*, ajuste fino, RLHF/DPO) fazem agentes baseados em LLM guiar o estudante com perguntas em vez de dar respostas diretas? **QP2** (memória, raciocínio e controle de estado) – que técnicas de memória (histórico, modelo do estudante), raciocínio (*chain-of-thought*) e controle de estado (máquinas de estados, escadas de dicas) regulam o suporte e evitam a revelação prematura da resposta? **QP3** (resistência à pressão) – como os agentes detectam e respondem a tentativas de obter a resposta (insistência, frustração, *jailbreaks*)?

Busca. Os termos foram derivados via PICO: população, contextos educacionais (implícita); intervenção, agentes ou tutores baseados em LLM; comparação, não se aplica; e resultado, comportamento socrático e *scaffolding*. A *string*, aplicada a título, resumo e palavras-chave, foi:

```
("large language model*" OR LLM* OR "generative AI" OR
GPT* OR ChatGPT OR "conversational agent*") AND (tutor*
OR "pedagogical agent*" OR "teaching assistant*" OR
"educational chatbot*") AND (Socratic OR scaffold* OR
"guided question*" OR "guiding question*" OR guardrail*
OR "answer leak*" OR "withhold* answer*" OR "pedagogical
alignment" OR "productive struggle")
```

A busca foi executada em 09/10/2026 em quatro bases, considerando publicações de 2022 até a data de corte de 03/10/2026: IEEE Xplore (77 resultados), ACM DL (47), Scopus (13 resultados, com a busca restrita ao título, dos quais 10 foram pré-selecionados pela

Tabela 1. Critérios de inclusão (CI) e exclusão (CE).

CI1	Estudo primário que apresenta ou avalia agente/tutor educacional baseado em LLM
CI2	O agente guia o estudante por perguntas, *scaffolding* ou retenção da resposta
CI3	Descreve ao menos uma técnica relacionada às QP1–QP3 (texto completo)
CI4/CI5	Publicado entre 2022 e 03/10/2026; em inglês ou português
CE1	Tutor/*chatbot* que não usa LLM CE2 LLM apenas gera conteúdo, avalia ou responde, sem diálogo tutorial
CE3	Sem descrição técnica do agente (texto completo) CE4 Estudo secundário
CE5	Resumo estendido, pôster, editorial, tutorial ou palestra CE6 Texto inacessível CE7 Duplicata

equipe por título e resumo) e arXiv (141 resultados, dos quais 15 foram pré-selecionados pela equipe). O arXiv foi incluído para cobrir literatura cinzenta e trabalhos de PLN e IA pouco indexados nas demais bases. Um *preprint* com versão publicada foi unido a ela, mantendo-se a versão publicada. A busca foi validada com um conjunto de controle de seis estudos de referência definido no protocolo; nenhum foi recuperado (Seção 6).

Seleção. Os critérios estão na Tabela 1. CI3, CE3 e CE6 só são aplicáveis ao texto completo. Casos duvidosos na primeira etapa foram marcados como *talvez*. Regras de decisão registradas durante a triagem incluem: revelar a resposta após N tentativas atende a CI2; textos de até duas páginas e de consórcio doutoral caem em CE5; agentes *ensináveis* atendem a CI2 se retêm a resposta; e CE3 é satisfeito quando o mecanismo de orientação é descrito. Registros da Scopus e do arXiv pré-selecionados pela equipe seguiram direto ao texto completo, e a opinião do assistente sobre título e resumo foi registrada à parte.

Triagem. A triagem e a extração foram executadas por um assistente baseado em LLM (Claude, Anthropic) seguindo o protocolo. Cada decisão cita os critérios e uma evidência literal, verificada automaticamente contra o texto do artigo, e tudo foi registrado em um log auditável.

Classificação e extração. O esquema foi construído por *keywording*. O tipo de pesquisa segue [Wieringa et al. 2006]: *avaliação* quando o agente é usado em contexto real de ensino; *validação* para estudos de laboratório, simulação ou *benchmark*; e *proposta de solução* quando não há avaliação empírica com aprendizes. O formulário de extração registrou: arquitetura (agente único, multiagente ou híbrida LLM + componente simbólico), modelo base, técnicas das QP1–QP3 (com categorias emergentes, como *restrição de interface* e *aprendizado por reforço*), domínio, nível de ensino e tipo de avaliação.

4. Resultados

4.1. Fluxo de seleção e visão geral

A Figura 1 resume o processo de seleção. Dos 149 registros, 7 eram duplicatas, entre elas 3 *preprints* de estudos já incluídos em versão publicada. Na triagem por título e resumo, 47 registros foram excluídos e 95 seguiram ao texto completo (68 incluídos e 27 marcados como *talvez*). No texto completo, 28 foram excluídos, a maioria por não

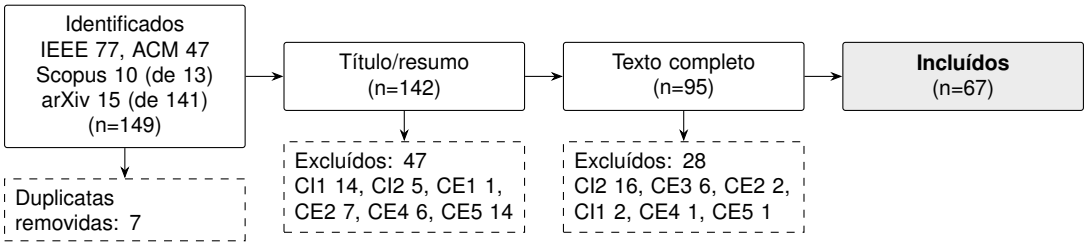


Figura 1. Fluxo de seleção dos estudos (no estilo PRISMA).

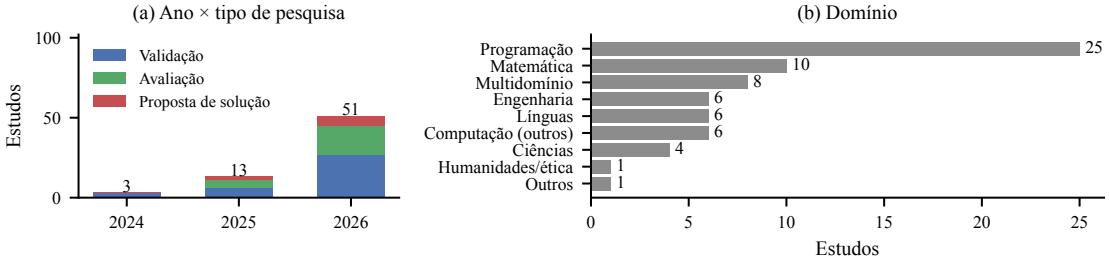


Figura 2. Estudos incluídos por (a) ano e tipo de pesquisa e (b) domínio.

guiar o estudante (CI2, 16) ou por não descrever o agente (CE3, 6). Restaram 67 estudos (IEEE 38, ACM 19, Scopus 5, arXiv 11, com sobreposição entre bases), dos quais 9 são literatura cinzenta (*preprints*). Dos 12 registros novos do arXiv, 8 foram incluídos. A lista completa e a classificação de cada estudo estão no material suplementar (`https://gist.github.com/lem3s/0f668628dde5437a3f18cb4d13540f62`).

A área é muito recente: 51 dos 67 estudos são de 2026, 13 de 2025 e 3 de 2024 (Figura 2a). Predominam pesquisas de validação (36), seguidas de avaliação em contexto real (23) e propostas de solução (8). Programação é o domínio dominante (25 estudos; Figura 2b), seguida de matemática (10), e a graduação é o nível mais frequente (29; educação básica em 11). Quanto à arquitetura, 40 estudos usam um agente único, 16 são multiagentes e 11 combinam o LLM com componentes simbólicos ou de aprendizado de máquina. Modelos da OpenAI são o motor do tutor em 27 estudos, modelos abertos em 14 e Gemini em 7; 14 não informam o modelo.

4.2. QP1: Indução do comportamento socrático

A indução por *prompt* é praticamente universal: 65 dos 67 estudos usam um *prompt* de sistema, 42 explicitam regras pedagógicas (por exemplo, “nunca forneça a solução” e “uma pergunta por turno”) e 23 atribuem uma persona. Um exemplo é o tutor “navegador”, cujo *prompt* evoluiu de “pergunte primeiro” para regras explícitas do que *não* fazer [Dobson and Karkalas 2026]. A recuperação aumentada (RAG, 19) ancora a orientação no material do curso, e plataformas *low-code* (6) permitem que docentes configurem os próprios tutores.

O treinamento aparece em 10 estudos, com ajuste fino supervisionado (8), otimização por preferência (3) ou aprendizado por reforço (4); metade (5) vem do arXiv e 8 usam modelos abertos. Com SFT e GRPO, um modelo de 7B elevou a eficácia do *scaffolding* de 30,0% para 63,3% e reduziu o vazamento de 30,0% para 13,3%, enquanto um modelo de 72B sem alinhamento vazou em 96,7% dos casos [Wang et al. 2026]. Outra

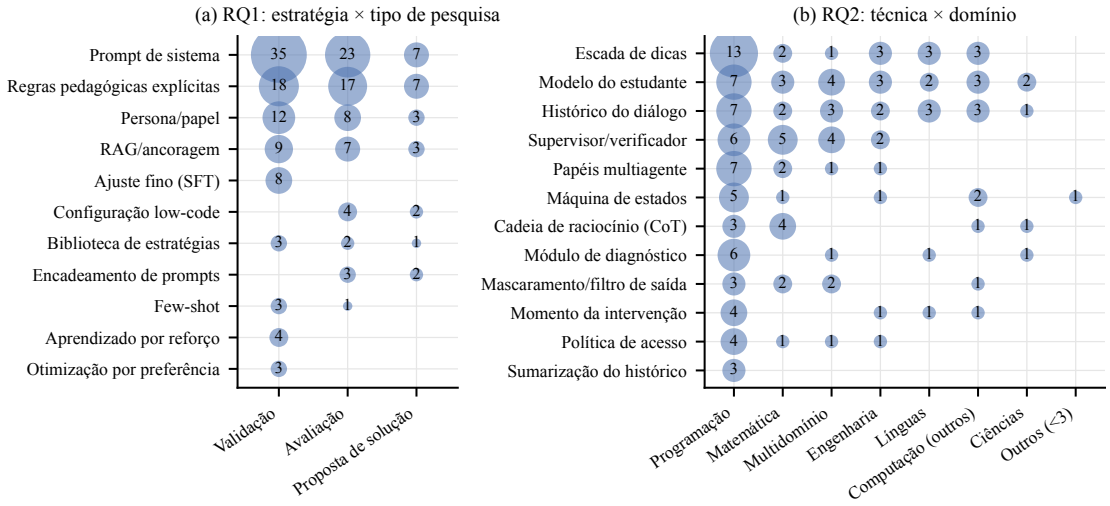


Figura 3. Mapas de bolhas: (a) estratégias da QP1 por tipo de pesquisa; (b) técnicas da QP2 por domínio. Um estudo pode ter várias técnicas.

linha recompensa também o raciocínio interno do tutor, e não só a resposta visível, o que deu a menor taxa de vazamento entre os modelos treinados [Lee et al. 2026]. Todos os 10 são pesquisas de validação; nenhum foi implantado em curso real (Figura 3a).

4.3. QP2: Memória, raciocínio e controle de estado

O mecanismo de controle mais frequente é a *escada de dicas* (25 estudos), que gradua a ajuda e, em vários casos, implementa a regra de revelar a resposta após N tentativas. Modelos do estudante (24) e o histórico do diálogo (21) sustentam a adaptação. Um agente de avaliação formativa, por exemplo, atualiza a cada turno um repositório de evidências para calibrar as dicas à ZDP [Cohn et al. 2026].

Uma tendência é *deslocar o controle para fora do LLM*: 21 estudos usam máquinas de estados (10), políticas de acesso (7) ou filtros de saída (8). Uma máquina de estados impõe três níveis de dica e proíbe código corrigido, por mais que o estudante insista [Yan et al. 2026]. Um núcleo de política sem LLM define o teto de uma escada de oito degraus apenas a partir do estado do aprendiz, sem ler o texto do estudante [Pisan 2026]. Uma função única de liberação verifica cada saída contra "contratos de revelação": o modo estrito reduziu os vazamentos detectados de 181 para 0, mas substituiu 581 de 599 respostas e reduziu a utilidade [Kadir 2026]. O próprio LLM também atua como supervisor antes da exibição (17) [Bassner et al. 2025]. A divisão em papéis multiagentes aparece em 11 estudos e a cadeia de raciocínio explícita em 9. A Figura 3b mostra que essas técnicas se concentram em programação.

4.4. QP3: Resistência à pressão do estudante

Apenas 31 dos 67 estudos relatam alguma técnica contra a busca pela resposta. As mais comuns são a recusa com redirecionamento (12), a detecção de intenção (10) e o tratamento de insistência (10). Um *middleware* detecta pedidos de resposta direta por regras e os converte em dicas [Aher et al. 2026]. Um tutor implantado detecta perguntas de tarefas avaliadas por similaridade com os enunciados e passa ao modo só-dicas [Liu et al. 2026].

Tabela 2. Estudos com avaliação adversarial (QP3). Todos são pesquisas de validação, exceto [Cohn et al. 2026].

Estudo	Contexto e ataque	Defesa	Resultado
[Shah et al. 2026]	900 diálogos simulados; atacante com 6 níveis de escalada	Supervisão por um segundo agente	Vazamento de 27,0% para 17,8%
[Kadir 2026]	480 sequências: pedido direto, codificado, encenação, cumulativo	Contratos de revelação, verificador e substituição	Sinalizações de 42 para 8; modo estrito com perda de utilidade
[Rayhan et al. 2026]	*Red-teaming*; consultas adversariais	Classificação de intenção e política de acesso	Vazamento de soluções de 91,7% para 25,0%
[Shao et al. 2026]	500 problemas, 5 disciplinas; 5 estratégias de *red-teaming*	SFT, DPO e alinhamento de representações	Taxa de colapso de 32%
[Zhao et al. 2026]	240 problemas; 6 famílias de ataque; atacante ajustado	Raciocínio prévio; juiz e refinador	Ex.: Qwen-32B, de 70% para 3–4%
[Pisan 2026]	Personas: insistente, engenharia social, injeção	Núcleo de política, detector de código, juiz	Respeito ao teto de ajuda de 54% para 100%
[Hasan and Nayeem 2026]	Persona de estudante "teimoso"	–	Modelos alinhados abandonam a persona
[Cohn et al. 2026]	Sala de aula (104 alunos); pressão para mudar notas	Construtos de consistência no *prompt*	Notas alteradas em menos de 1%

Uma escada adaptativa escala para um docente humano quando o aluno pede repetidamente a solução completa [Bartoš 2026]. Restrições de interface (3) substituem o *chat* livre por ações estruturadas; em um estudo de 12 semanas, os pedidos de solução caíram ao longo do tempo [Kumaran R and Mohan A 2026].

A avaliação adversarial é rara (8 estudos, 4 deles do arXiv, e apenas 1 em contexto real; Tabela 2). Três achados se repetem. Primeiro, o vazamento ocorre cedo: na maioria dos casos, nos dois primeiros turnos [Shah et al. 2026]. Segundo, ataques persuasivos superam pedidos diretos: a manipulação do contexto induziu vazamento médio de 74%, e um estudante atacante obtido por ajuste fino foi mais eficaz que os atacantes por *prompt* [Zhao et al. 2026]. Terceiro, as defesas eficazes ficam fora da geração da resposta, como supervisão por um segundo agente, raciocínio antes de responder, classificação de intenção com políticas de acesso e funções de liberação [Shah et al. 2026, Zhao et al. 2026, Rayhan et al. 2026, Kadir 2026]. Atacantes simulados, porém, tendem a abandonar a persona resistente por causa do próprio alinhamento, o que limita esses testes [Hasan and Nayeem 2026]. Em campo, estudantes contornam o tutor por reformulação, divisão do problema e enquadramento hipotético [Liu et al. 2026], e chegam a convencer o modelo a codificar a solução em base64 [Pisan 2026].

5. Discussão

Tendências. O "modo socrático" é, na maioria dos estudos, uma propriedade do *prompt*. Duas linhas tentam ir além. A primeira combina camadas fora do modelo: regras no

prompt, controle de estado determinístico e verificação antes da exibição, pois um LLM sozinho tende a "sair do personagem" sob pressão [Yan et al. 2026, Shah et al. 2026] e nenhuma edição isolada do *prompt* produziu um tutor que retém a resposta [Pisan 2026]. A segunda internaliza a retenção nos pesos, com recompensas que penalizam o vazamento. As linhas são complementares e têm custos: guardas estritas reduzem a utilidade e podem bloquear ajuda legítima [Kadir 2026, Pisan 2026], e a penalidade de revelação piorou o modelo quando usada como recompensa, embora funcionasse como restrição na inferência [Wang et al. 2026].

Lacunas. (i) A resistência à pressão é pouco avaliada, quase sempre com estudantes simulados e raramente em sala de aula. (ii) A evidência de aprendizagem é escassa e mista. Entre as 23 pesquisas de avaliação, apenas 10 medem resultados de aprendizagem, e nenhum dos 8 novos estudos do arXiv mede a aprendizagem de estudantes reais. Um experimento randomizado não encontrou diferenças entre um tutor socrático, um *chatbot* genérico e nenhum apoio [Bassner et al. 2025]; outro observou maiores ganhos posteriores com orientação socrática do que com o ensino de refinamento de *prompts* [Brender et al. 2026]. (iii) O treinamento ainda não saiu do laboratório e é avaliado sobretudo por juízes LLM. (iv) Falhas sutis, como elogios infundados, a reformulação da resposta pelo próprio tutor [Cardell-Oliver et al. 2026] ou nomear o erro exato em prosa, só começam a ser tratadas [Pisan 2026]. (v) O contorno por ferramentas externas exige medidas no desenho da atividade, não só no agente. (vi) Programação e ensino superior predominam, e nenhum estudo em português foi encontrado.

Implicações. Para desenvolvedores, recomenda-se não depender apenas do *prompt*: a decisão de revelar deve ser explícita, tomada por um componente que o estudante não consiga persuadir e verificada antes da exibição; o tutor deve ser testado contra atacantes que escalam a pressão e manipulam o contexto [Shah et al. 2026, Zhao et al. 2026], medindo também o excesso de bloqueio. Para pesquisadores, são necessários *benchmarks* adversariais compartilhados e estudos em sala de aula que meçam aprendizagem, e não apenas percepção ou vazamento.

6. Ameaças à Validade

Validade descritiva. A triagem e a extração foram feitas por um assistente baseado em LLM, sem triagem independente por um segundo revisor, o que pode introduzir viés sistemático. Os textos foram lidos a partir de conversões automáticas de PDF.

Validade teórica. A busca restringiu-se a quatro bases. Da Scopus e do arXiv foram usados apenas registros pré-selecionados pela equipe (10 de 13 e 15 de 141), sem registro dos motivos das exclusões feitas nessa pré-seleção. Nenhum estudo do conjunto de controle foi recuperado (0/6): a maioria deles foi publicada em veículos de PLN ou como relatório técnico, e vários são citados pelos estudos incluídos, o que indica que o *snowballing* deve recuperá-los. Bases de PLN (ACL Anthology) e brasileiras não foram consultadas.

Generalização. Como 51 dos 67 estudos são de 2026, o mapa é um retrato de uma área em rápida mudança. Programação e ensino superior estão sobrerrepresentados. Há 9 *preprints* sem revisão por pares, avaliados com critérios de qualidade de literatura cinzenta.

Validade interpretativa. A atribuição do tipo de pesquisa e a fronteira entre

categorias próximas (por exemplo, regras pedagógicas e *prompt* de sistema) envolvem julgamento.

7. Conclusão

Quanto à QP1, a indução se faz quase sempre por *prompt*; o treinamento específico (SFT, preferência e reforço) cresce, sobretudo em *preprints*, mas permanece restrito ao laboratório. Quanto à QP2, escadas de dicas e modelos do estudante dominam o controle, com tendência a deslocá-lo para componentes determinísticos ou supervisores que decidem o que pode ser revelado. Quanto à QP3, menos da metade dos estudos trata a pressão por respostas, e poucos a avaliam de forma adversarial, quase sempre com estudantes simulados. Trabalhos futuros: realizar o *snowballing*, ampliar a busca a bases de PLN e brasileiras e construir um *benchmark* adversarial compartilhado para tutores socráticos, validado com estudantes reais.

Referências

[Abdelghani et al. 2026] Abdelghani, R., Kaiser, P., and Murayama, K. (2026). Regulating the AI Tutor: Intentions, Help-Seeking, and Self-Regulated Learning in Adolescent GenAI Use. arXiv preprint arXiv:2606.08568.

[Aher et al. 2026] Aher, C., Nehete, C., Magar, A., and Patil, H. (2026). The "Think-First" Architecture: A Middle-ware System for Mitigating Cognitive Offloading in Generative AI Tutors. In *2026 1st International Conference on Innovation & Growth in Next-Gen Intelligent Technology & Engineering (IGNITE)*.

[Bartoš 2026] Bartoš, P. (2026). Adaptive large language model scaffolding supports online programming education through learning analytics and knowledge tracing. *Discover Education (2026) 5:943*.

[Bassner et al. 2025] Bassner, P., Lottner, A., and Krusche, S. (2025). Towards Understanding the Impact of Context-Aware AI Tutors and General-Purpose AI Chatbots on Student Learning. In *25th Koli Calling International Conference on Computing Education Research (Koli Calling '25)*.

[Beale 2025] Beale, R. (2025). Dialogic Pedagogy for Large Language Models: Aligning Conversational AI with Proven Theories of Learning. arXiv preprint arXiv:2506.19484.

[Brender et al. 2026] Brender, J., El-Hamamsy, L., Uittenhove, K., Perez, A., Jermann, P., Mondada, F., and Bumbacher, E. (2026). Reflective Dialogue or Prompt Refinement? Effects of Tutor Scaffolding on Students' Independent LLM Use for Programming. arXiv preprint arXiv:2607.03303 [cs.AI].

[Cardell-Oliver et al. 2026] Cardell-Oliver, R., Szabo, C., Maennel, K., and Russell, H. (2026). LLM-led Socratic Dialogues on Ethics in Computing. In *Proceedings of the 31st ACM Conference on Innovation and Technology in Computer Science Education V. 1 (ITiCSE 2026)*.

[Cohn et al. 2026] Cohn, C., Rayala, S., Srivastava, N., Fonteles, J. H., Jain, S., Luo, X., Mereddy, D., Mohammed, N., and Biswas, G. (2026). A Theory of Adaptive Scaffolding for LLM-Based Pedagogical Agents. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-26)*.

[Dobson and Karkalas 2026] Dobson, L.-R. T. and Karkalas, S. (2026). Exploring Minimally Intrusive GenAI Scaffolding for Introductory Programming Education. In *2026 14th International Conference on Software and Information Engineering (ICSIE 2026)*.

[El Yabouri and Hibbi 2026] El Yabouri, H. and Hibbi, F.-Z. (2026). A Multi-Dimensional Framework for Adaptive Scaffolding in Large Language Model. In *2026 6th International Conference on Innovative Research in Applied Science, Engineering and Technology (IRASET)*.

[Hasan and Nayeem 2026] Hasan, U. and Nayeem, M. A. (2026). Twin Minds in Code Education: Simulating Student-Tutor Dynamics using LLMs as Cognitive Digital Twins. In *2026 23rd International Learning and Technology Conference (L&T)*.

[Kadir 2026] Kadir, N. (2026). Auditable Release Control for Pedagogical Leakage in LLM Tutors. arXiv preprint arXiv:2608.00515.

[Kitchenham and Charters 2007] Kitchenham, B. and Charters, S. (2007). Guidelines for Performing Systematic Literature Reviews in Software Engineering. Technical Report EBSE-2007-01, Keele University and Durham University.

[Kumaran R and Mohan A 2026] Kumaran R and Mohan A (2026). Leveraging Generative AI for Cognitive Skill Enhancement in Low-Performing Programming Learners. In *2026 4th International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT)*.

[Lee et al. 2026] Lee, U., Bae, J., Park, J., Park, H., Park, T., Jeon, Y., Cho, S., Koh, J., Jeong, Y., and Lee, G. (2026). Rewarding How Models Think Pedagogically: Integrating Pedagogical Reasoning and Thinking Rewards for LLMs in Education. arXiv preprint arXiv:2601.14560.

[Liu et al. 2026] Liu, C., Hoang, L., Kizilcec, R. F., and Wu, B. (2026). A Large-Scale Analysis of Student Behavior with Pedagogically Constrained LLM Tutors. In *Proceedings of the Thirteenth ACM Conference on Learning @ Scale (L@S '26)*.

[Perez 2026] Perez, R. M. (2026). Large language models for education: An open-source paradigm for automated Q&A in the graduate classroom. *Computers and Education: Artificial Intelligence, 10 (2026) 100546*.

[Petersen et al. 2008] Petersen, K., Feldt, R., Mujtaba, S., and Mattsson, M. (2008). Systematic Mapping Studies in Software Engineering. In *Proceedings of the 12th International Conference on Evaluation and Assessment in Software Engineering (EASE)*, pages 68–77.

[Petersen et al. 2015] Petersen, K., Vakkalanka, S., and Kuzniarz, L. (2015). Guidelines for Conducting Systematic Mapping Studies in Software Engineering: An Update. *Information and Software Technology*, 64:1–18.

[Pisan 2026] Pisan, Y. (2026). Teaching a Large Language Model Tutor to Withhold the Answer: A Supervisor Architecture and an Evidence-Driven Method for Tuning Socratic Behavior. arXiv preprint arXiv:2608.12292.

[Ramadhan and Falih 2025] Ramadhan, V. J. and Falih, N. (2025). Conversational Learning Architectures for Vocabulary Acquisition: A Systematic Literature Review of LLM

and Spaced Repetition Approaches. In *2025 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)*.

[Rayhan et al. 2026] Rayhan, M. H., Edwards, G. R., Pandey, A., Seth, V., Salvi, N., Glaser, N., Chrysochoou, M., and Calyam, P. (2026). SAGE: Student-Focused Adaptive Guidance Engine for Intelligent Tutoring with Regulated Learning. In *2026 IEEE International Conference on Human-Machine Systems (ICHMS)*.

[Shah et al. 2026] Shah, S. T., Mohamed, M., and Mohamed, A. (2026). Benchmarking and Mitigating Answer Leakage in LLM Tutoring Under Persistent Student Pressure. In *Western Canada Conference on Computing Education (WCCCE 2026)*.

[Shao et al. 2026] Shao, J., Wu, Q., Zhang, H., Sun, S., and Zhuang, J. (2026). Mitigating Scaffolding Collapse in Socratic Tutors via Representation Alignment. arXiv preprint arXiv:2607.19371.

[Wang et al. 2026] Wang, X., Song, S., Liu, W., and Zou, X. (2026). Beyond Direct Answering: Aligning Educational LLMs as Socratic Guides via Heuristic Reinforcement Learning. arXiv preprint arXiv:2607.22996.

[Wieringa et al. 2006] Wieringa, R., Maiden, N., Mead, N., and Rolland, C. (2006). Requirements Engineering Paper Classification and Evaluation Criteria: A Proposal and a Discussion. *Requirements Engineering*, 11(1):102–107.

[Yan et al. 2026] Yan, D., Yang, J., Wu, Z., and Zhang, X. (2026). Graph-Based Semantic Diagnosis and Progressive Dialogue Framework for Programming Education.

[Zhao et al. 2026] Zhao, J., Knežević, M., and Käser, T. (2026). Evaluating Answer Leakage Robustness of LLM Tutors against Adversarial Student Attacks. arXiv preprint arXiv:2604.18660.